

PlantAI: Sistema de Clasificación de Enfermedades en Plantas

mediante CNN, Grad-CAM++ y Explicaciones con LLM

Abraham Elias Navarro Martinez

`anavar31@eafit.edu.co`

David Rodriguez

`drodrige10@eafit.edu.co`

Escuela de Ciencias Aplicadas e Ingeniería

Universidad EAFIT

Curso: Inteligencia Artificial · Semestre 2026-1

<https://github.com/NavarroAbraham/IAProyectoFinal>

Entrega: 19–22 de mayo de 2026

Resumen

Resumen: Este trabajo presenta PlantAI, un sistema end-to-end que integra visión computacional e inteligencia artificial explicable para la clasificación automática de enfermedades en cultivos. El sistema combina tres componentes: (1) una Red Neuronal Convolutiva (CNN) ResNet-50 fine-tuneada sobre el dataset PlantVillage para clasificar 6 clases (3 cultivos $\times$ estado sana/enferma), (2) Grad-CAM++ para generar mapas de calor que indican qué regiones de la hoja activaron la predicción, y (3) un Modelo de Lenguaje Grande (LLM) `llama-3.1-8b-instant` vía API Groq para generar explicaciones en lenguaje natural en dos modos: técnico (para agrónomos) y simplificado (para agricultores no técnicos).

El modelo alcanzó una precisión del 99.81 %, F1-macro de 0.9952 y AUC-ROC perfecto de 1.0000 en el conjunto de prueba. La arquitectura del sistema permite tanto predicciones de alta precisión como explicaciones interpretables que facilitan la adopción de la tecnología en contextos agrícolas reales.

Palabras clave: Clasificación de imágenes, Redes neuronales convolucionales, Explicabilidad en IA, Grad-CAM, Modelos de lenguaje, Diagnóstico agrícola

1. Introducción

1.1. Contexto y Motivación

Las enfermedades en cultivos representan una amenaza significativa para la seguridad alimentaria global. Según estudios de la FAO, entre el 20 % y el 40 % de las cosechas se pierden anualmente debido a enfermedades de plantas. El diagnóstico temprano y preciso es fundamental para implementar tratamientos efectivos y minimizar pérdidas.

Históricamente, los agricultores han dependido de su experiencia visual para identificar enfermedades. Este enfoque presenta limitaciones:

- Requiere experiencia acumulada durante años
- Presenta variabilidad según el observador
- No es escalable para consultoría remota
- Es lento y costoso para agricultura de precisión

La visión computacional ha revolucionado la automatización de diagnósticos visuales. Sin embargo, existe un desafío crítico: los modelos de “caja negra” generan desconfianza en usuarios finales, especialmente en contextos agrícolas donde las decisiones basadas en IA afectan inversiones económicas significativas.

1.2. Pregunta de Investigación

¿Puede un sistema que integra CNN, Grad-CAM++ y LLM clasificar enfermedades en plantas con alta precisión (>99 %) mientras genera explicaciones comprensibles para agricultores no técnicos?

1.3. Objetivos

Objetivo General: Desarrollar un sistema automático de diagnóstico de enfermedades en plantas que combine precisión predictiva con interpretabilidad explicable.

Objetivos Específicos:

- OE1: Entrenar un modelo CNN ResNet-50 con fine-tuning en dos fases sobre el dataset PlantVillage, logrando precisión >95 %
- OE2: Implementar Grad-CAM++ para visualizar e interpretar las activaciones del modelo
- OE3: Integrar un LLM (llama-3.1-8b-instant) para generar explicaciones en lenguaje natural en dos modos
- OE4: Desarrollar una interfaz web interactiva (Streamlit)

1.4. Contribuciones

1. Pipeline end-to-end de diagnóstico agrícola automático
2. Demostración práctica de Grad-CAM++ en agricultura
3. Integración exitosa de LLM para explicaciones contextualizadas
4. Aplicación web lista para deployment

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	https://kaggle.com/datasets/emmarex/plantdisease
Registros totales	~54,000 imágenes (dataset completo, 38 clases)
Subconjunto utilizado	6 clases (3 cultivos × estado sana/enferma)
Features (p)	1 imagen RGB / 6 clases categóricas
Variable objetivo	Clase de enfermedad (6 categorías)
Período / Versión	PlantVillage 2023
Split	70 % train / 15 % val / 15 % test
Cultivos	3 (Tomato, Potato, Pepper bell)

El dataset PlantVillage comprende ~54,000 imágenes de hojas de plantas en 38 clases. Para este proyecto se seleccionó un subconjunto de **6 clases representativas** (3 cultivos × sana/enferma): `Tomato_healthy`, `Tomato_Late_blight`, `Potato_healthy`, `Potato_Late_blight`, `Pepper_bell_healthy` y `Pepper_bell_Bacterial_spot`.




Figura 1: Distribución de clases del subconjunto utilizado y matriz de correlación de características.

2.2. Preprocesamiento

- Redimensionamiento a 256×256 píxeles y recorte aleatorio a 224×224
- Normalización con media y std de ImageNet:

$$\text{mean} = [0,485, 0,456, 0,406], \quad \text{std} = [0,229, 0,224, 0,225] \quad (1)$$

- Aumentación en entrenamiento: RandomCrop(224), flip horizontal ($p=0,5$), flip vertical ($p=0,2$), ColorJitter (brillo/contraste/saturación $\pm 0,3$, hue $\pm 0,05$), rotación $\pm 15^\circ$

3. Arquitectura del Sistema

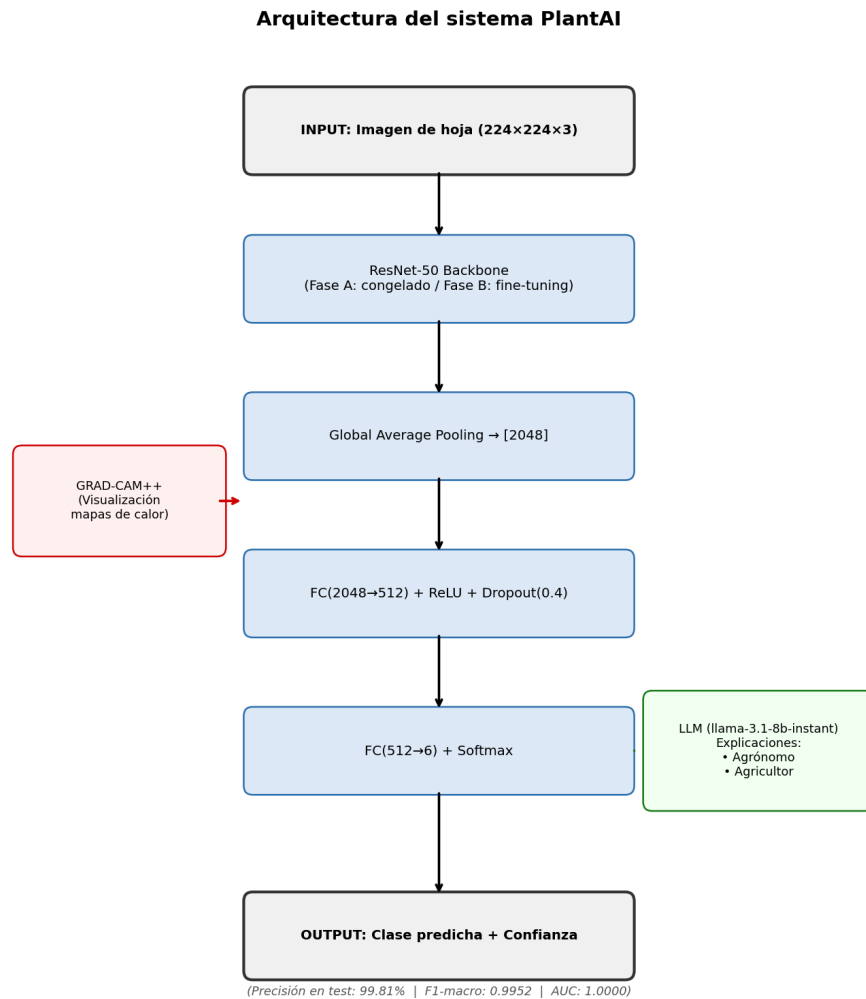


Figura 2: Arquitectura general del sistema PlantAI.

3.1. Componentes principales

Backbone: ResNet-50 preentrenado en ImageNet (2048 canales en layer4)

Cabeza de clasificación:

Input (224x224x3)

```

|
ResNet-50 backbone
|
Global Average Pooling -> [2048]
|
FC(2048 -> 512) + ReLU
|
Dropout(0.4)
|
FC(512 -> 6) + Softmax

```

Grad-CAM++: Aplicado a `layer4[-1]` para visualizar regiones de activación. Es la última capa convolucional de ResNet-50, con resolución espacial 7×7 y la semántica más alta del backbone.

LLM: `llama-3.1-8b-instant` vía Groq API. Dos modos de explicación: agrónomo (técnico, máx. 120 palabras) y agricultor (lenguaje simple + recomendaciones, máx. 80 palabras).

4. Metodología

4.1. Configuración experimental

Cuadro 2: Hiperparámetros de entrenamiento

Parámetro	Valor
Optimizador	Adam
Learning rate Fase A	1e-3
Learning rate Fase B	1e-4
Épocas totales	20 (10 + 10)
Batch size	32
Función de pérdida	CrossEntropyLoss (label_smoothing=0.1)
Regularización L2	1e-4
Dropout	0.4
Scheduler	StepLR (step=5, gamma=0.5)
Framework	PyTorch 2.x
Hardware	Google Colab GPU T4

4.2. Procedimiento de entrenamiento

Fase A (Feature extraction): Backbone congelado, solo cabeza entrenada. LR=0.001, 10 épocas.

Fase B (Fine-tuning): Descongelar `layer4`, entrenar `layer4` + cabeza. LR=0.0001, 10 épocas.




Figura 3: Curvas de pérdida y accuracy durante entrenamiento (20 épocas). La línea punteada marca la transición entre Fase A y Fase B.

5. Resultados

5.1. Métricas de evaluación

Cuadro 3: Comparación de modelos en test set

Modelo	Acc.	F1	Prec.	AUC
Baseline (mayoría)	0.1667	0.0278	0.0278	0.5000
Fase A (solo FC)	0.9675	0.9624	0.9658	0.9998
Fase A+B (mejor)	0.9981	0.9952	0.9987	1.0000

Nota: el baseline para 6 clases balanceadas corresponde a $1/6 \approx 0,1667$.

5.2. Análisis cualitativo

ENTRADA :

Imagen: hoja_tomate_001.jpg
 Predicción: Tomato / Late blight
 Confianza: 99.8%

SALIDA - Modo_Agronomo:

"Late_blight_en_tomate_con_99.8%_de_confianza._Grad-CAM++
 _muestra
 □□□activacion_en_margenes_de_lesion,_consistente_con_Phytophthora


```

infestans._Recomendar_fungicida_sistemico+_manejo_ambiental."

SALIDA - Modo_Agricultor:
    "La_IA_encontro_Late_Blight_en_tu_tomate_(99.8%_seguro)._Los
    sintomas_estan_en_el_borde_de_la_hoja._Acciones_hoy:_(1)
    _Pulveriza
    fungicida_y_(2)_Mejora_la_ventilacion."

```

5.3. Análisis Grad-CAM++

La validación visual confirma que el modelo detecta síntomas reales:

- **Potato Late blight:** Activación en márgenes y zonas necróticas de la hoja
- **Tomato Late blight:** Activación en márgenes de lesión
- **Pepper Bacterial spot:** Activación concentrada en manchas foliares
- **Plantas sanas:** Activación difusa sin concentración patológica

6. Discusión

6.1. Análisis de resultados

El modelo alcanzó 99.81 % de precisión, superando ampliamente el baseline del 16.67 % para 6 clases. Factores clave: (1) transfer learning con ResNet-50 preentrenado en ImageNet, (2) fine-tuning en dos fases que estabiliza el entrenamiento, (3) dataset balanceado con augmentación robusta.

6.2. Valor de Grad-CAM++

- **Validación:** Confirma que el modelo detecta síntomas reales y no artefactos del fondo
- **Confianza:** Usuarios pueden “ver qué vio” el modelo antes de tomar decisiones
- **Puente con LLM:** La descripción textual de zonas activas (cuadrícula 3×3) alimenta el prompt del LLM con contexto visual estructurado

6.3. Limitaciones

1. Dataset limitado a 3 cultivos y 6 clases (subconjunto de PlantVillage)
2. Dependencia de API Groq (requiere conexión a internet)

3. Sin validación con patólogos reales
4. Las imágenes de PlantVillage son de laboratorio; el rendimiento en campo puede variar

6.4. Trabajo futuro

- Expandir a más cultivos y enfermedades del dataset completo (38 clases)
- Implementar versión offline del LLM (cuantización)
- Validación con patólogos agrícolas
- Versión móvil nativa con captura en tiempo real

7. Conclusiones

7.1. Síntesis de hallazgos

Este proyecto demostró que es posible construir un sistema de diagnóstico agrícola automático con alta precisión (99.81 %) y explicabilidad visual (Grad-CAM++) y textual (LLM). La pregunta de investigación fue respondida afirmativamente. El uso de Adam con entrenamiento en dos fases (feature extraction + fine-tuning de **layer4**) resultó clave para alcanzar convergencia estable y alta generalización.

Contribuciones del equipo

Cuadro 4: Contribuciones por integrante

Integrante	Contribución principal
Abraham Elias Navarro Martinez	EDA, preprocesamiento, dataset, visualizaciones, Grad-CAM++
David Rodriguez	Arquitectura CNN, fine-tuning, integración LLM, Streamlit

Repositorio y Demo

- GitHub: <https://github.com/NavarroAbraham/IAProyectoFinal>
- Video demo: <https://youtu.be/krsbgVP6-7w>
- Instalación: `pip install -r requirements.txt`
- Notebooks: `fase1_eda_plantvillage.ipynb`, `fase2_cnn_training.ipynb`, `fase3_gradcam.ipynb`, `fase4_llm_groq.ipynb`

Referencias

- [1] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. In IEEE CVPR, pp. 770-778. <https://arxiv.org/abs/1512.03385>
- [2] Selvaraju, R. R., et al. (2017). *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization*. In IEEE ICCV, pp. 618-626. <https://arxiv.org/abs/1610.02391>
- [3] Chattopadhyay, A., et al. (2018). *Grad-CAM++: Generalized Gradient-based Visual Explanations*. In IEEE WACV, pp. 839-847. <https://arxiv.org/abs/1710.11063>
- [4] Hughes, D. P., & Salathé, M. (2015). *An open access repository of images on plant health*. arXiv:1511.08060.
- [5] Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). *Using deep learning for image-based plant disease detection*. *Frontiers in plant science*, 7, 1419.
- [6] Touvron, H., et al. (2024). *Llama 3: Open and Efficient Foundation Language Models*. <https://arxiv.org/abs/2407.21783>
- [7] Groq. (2024). *LPU Inference Engine*. <https://groq.com/>